Xử lý ngôn ngữ tự nhiên

Lab 08 (w8)

Calculation

Ex1			
	cat	0,1	
	dog	0,05	
	eats	0,7	← Mask
	fish	0,15	

=> $L = -\log(0,7)$

1)
Với eats 0,95 → $L = -\log(0,95)$ → ↓ nhỏ

2)
Với eats 0,01 → $L = -\log(0,01) \approx 4,6$
=> ↑

tức ở đây nếu nhãn (mask) thật là eat mà predict ra thấp => Loss lớn
=> update gradient ~~mạ~~ (maybe với bước lớn hơn, đây loại phạt nặng hơn với loss nhỏ)

3) Phù hợp với Btoán này vì
- Btoán yêu cầu cần đoán ra 1 từ điền vào mask trong ~~|V|~~
trong tập rời rạc có kích thước |V|
=> phân loại class (multi classification)
- cơ chế phạt theo lượng tin bất ngờ

Ex2 "The cat are playing"   tokenizer Sd "bert-base-uncased"

↳) chuỗi hoá "the cat are playing"

Token sequence để ~~đưa~~ đưa vào Bert

⇒ ['[CLS]' 'the' 'cat' 'are' 'playing' '.' '[SEP]']

↳) token id

[CLS] → 101
the → 1996
cat → 8870
are → 2024
playing → 2652
. → 1012
[SEP] → 102

⇒ [101 1996 8870 2024 2652 1012 102] (len = 7)

↳) Mask [1 1 1 1 1 1 1]

Mask + Padding [1 1 1 1 1 1 1 0 0 0]

Số từ 4

Số token 7

Subword 5 đơn vị do số từ này ~~không~~ thông dụng
⇒ có nguyên trong bộ từ điển của Bert

Prediction

1) Pretrain Transformer fine tuning đạt kết quả tốt hơn
vì pretrained model (như bert) đã được học cú pháp, ngữ nghĩa từ nhiều văn bản tổng quát,
Transformer train from scratch học từ đầu với IMDB lớn hơn => có thể overfit + thiếu tính tổng quát

2) Chưa thể dự đoán luôn được, cần thực nghiệm thực tế

3) Có 10% data training => from scratch ↓ mạnh do Pretrain đã có tri thức nền tảng => 10% data là đủ để học, ánh xạ
Model scratch => data quá ít để học => model overfit nghiêm trọng => tụt hiệu năng